

基于扩散模型的多视角 相机镜头控制图像生成

技术报告 (Technical Report)

项目名称: 多模态应用——相机镜头控制图像生成
报告类型: 技术报告
运行硬件: NVIDIA RTX 4060 16G
日期: 2026 年 7 月 12 日

本报告系统阐述面向 AI 图像生成镜头控制任务的多模态条件扩散方案:
以参考图结构图 (深度图/轮廓图) 与相机相对旋转向量为条件,
基于 InstructPix2Pix 底模进行 LoRA 微调, 实现目标视角结构图的生成,
并经多步迭代扩展至任意大角度视角变换。

前言

当下以 Stable Diffusion 为代表的文生图扩散模型已经能够根据文本提示词生成质量极高的图像，但在镜头角度、空间结构、物体轮廓与多视角一致性等方面的控制能力依然有限：文本对镜头的控制本质上是不稳定的，例如输入”俯拍””近景””镜头向左移动”，模型往往只能生成一个”看起来差不多”的画面，却并未真正理解相机的位置、角度与视场等几何信息。换言之，普通 prompt 更多控制的是语义与风格，而非严格的空间结构。

本技术报告所记录的工作，目标不在于单张图片的随机生成，而在于：给定一张参考图与相机相对旋转的三维向量提示词，让扩散模型生成同一物体在目标视角下、且尽量保持结构、身份、材质与光照一致性的图像。为达成这一目标，我们将抽象的相机控制转化为模型可理解的结构控制——通过深度图与 Canny 轮廓图这两类中间条件图，再借助 ControlNet 的结构注入能力与 LoRA 的轻量化微调，使扩散模型在生成时受到明确的几何约束。

整套系统并非已经完全实现了严格的六自由度（6DoF）相机控制，更准确的定位是一个”基于深度图、Canny 轮廓图、LoRA 与 ControlNet 的镜头控制原型系统”。它验证了一个核心思路：通过中间结构条件，可以让扩散模型更稳定地服从镜头控制，从而为后续的多视角一致生成与连续镜头生成打下基础。

本报告的章节安排如下：第一章为绪论，交代问题背景、目标与贡献；第二章梳理相关工作；第三章详述整体方法设计；第四章介绍基于 Blender 的多视角数据集构建管线；第五章给出训练、收敛验证、推理应用与 ComfyUI 部署的实现细节；第六章对结果与局限进行分析讨论；第七章总结全文并展望未来工作。

目录

前言：从文生图到镜头控制	2
第一章 绪论	5
1.1 研究背景与动机	5
1.2 问题定义	5
1.3 主要贡献	6
1.4 章节安排	6
第二章 相关工作	7
2.1 扩散模型与文生图	7
2.2 扩散模型的条件控制	7
2.3 参数高效微调：LoRA	7
2.4 单目深度估计	8
2.5 新视角合成	8
2.6 CLIP 与多模态对齐	8
第三章 整体方法设计	9
3.1 总体架构	9
3.2 底模选择：InstructPix2Pix	10
3.3 双分支设计	10
3.4 条件注入机制	10
3.4.1 结构图条件注入	11
3.4.2 旋转向量条件注入	11
3.4.3 分类器无关引导（CFG）	12
3.5 LoRA 微调策略	12
3.6 训练策略：相邻视角配对	12
3.7 推理策略：多步迭代大角度变换	13
第四章 基于 Blender 的多视角数据集构建管线	14
4.1 场景搭建	14

4.2	相机轨迹生成	15
4.3	批量渲染	15
4.4	条件图后处理	16
4.5	数据集拆分	16
4.6	数据集规模与标注格式	16
第五章	实现细节	18
5.1	训练流程	18
5.1.1	模型加载与 LoRA 挂载	18
5.1.2	数据集与 DataLoader	18
5.1.3	训练循环	18
5.2	显存优化	19
5.3	收敛验证	19
5.4	推理应用	20
5.4.1	Gradio 交互界面	20
5.4.2	双模式推理	20
5.5	ComfyUI 工作流部署	21
5.6	运行环境与依赖	21
第六章	实验结果与局限分析	22
6.1	实验设置	22
6.1.1	数据集	22
6.1.2	训练配置	22
6.1.3	硬件环境	22
6.2	定性结果	23
6.2.1	小角度变换	23
6.2.2	大角度多步迭代	23
6.2.3	双分支对比	23
6.3	定量评估	24
6.3.1	Loss 收敛曲线	24
6.3.2	结构相似性	24
6.4	局限性与讨论	24
第七章	总结与展望	26
7.1	工作总结	26
7.2	未来工作展望	26

第一章 绪论

1.1 研究背景与动机

近年来，以 Stable Diffusion^[?]] 为代表的文生图（Text-to-Image）扩散模型在图像生成质量上取得了突破性进展。然而，当任务从”根据文本描述生成一张好看的图片”转变为”精确控制生成图像的相机视角与空间结构”时，现有模型暴露出明显局限——文本 prompt（如”俯拍””镜头向左移动”）本质上只能提供语义层面的模糊引导，模型难以精确理解相机的位置、角度、视场等几何信息，导致生成结果的视角不可控、结构不稳定^[?]]。

与此同时，在电影摄影、3D 内容创作、虚拟现实等应用场景中，用户对多视角一致性和精确镜头控制的需求日益增长。例如，给定物体的正面参考图，用户期望生成该物体从侧面、顶部等目标视角观察时所见的外观。这类任务要求模型不仅理解图像内容，还需具备对三维空间变换的推理能力。NeRF^[?]] 与 3D Gaussian Splatting^[?]] 等方法可以从多视角图像集合中重建场景并合成新视角，但它们通常需要数十至上百张标定图像作为输入，难以从单张参考图直接泛化。

本项目的核心动机在于：**能否让扩散模型以单张参考图为输入，结合显式的相机旋转条件，直接生成目标视角下的、结构一致的多视角图像？**为实现这一目标，我们将抽象的相机控制问题转化为扩散模型可理解的结构控制问题——通过深度图（Depth Map）与轮廓图（Canny Edge Map）作为中间条件表示，借助 ControlNet 的条件注入能力与 LoRA 的轻量化微调，构建一个面向 AI 图像生成镜头控制的多模态条件扩散原型系统。

1.2 问题定义

本项目的核心任务可形式化定义为：给定一张参考图像 I_{ref} 与一个三维相机相对旋转向量 $\mathbf{r} = [\Delta\theta_{\text{azimuth}}, \Delta\theta_{\text{elevation}}, \Delta\theta_{\text{roll}}]^\top$ （单位：度），生成目标视角下的结构图 I_{target} ，使得 I_{target} 在物体结构、轮廓与空间关系上与真实目标视角尽可能一致。系统采用 InstructPix2Pix^[?]] 作为基础扩散模型，在其 UNet 的注意力层上挂载 LoRA 适配器，仅微调少量参数以适应这一新任务；推理阶段通过将大角度旋转分解为多个小步长、串联迭代生成的方式支持任意角度的视角变换。

1.3 主要贡献

本文的主要贡献包括：

- (1) **结构图视角变换方案**：提出以深度图/轮廓图作为中间表示，基于 InstructPix2Pix 原生 8 通道 UNet 进行 LoRA 微调，实现”参考结构图 + 旋转向量 $\rightarrow$ 目标结构图”的条件生成，避免了从零训练条件注入权重的开销。
- (2) **RotationEncoder 旋转条件编码**：设计三维旋转向量的 sin/cos 编码方案与 MLP 映射模块，将其转换为可与 CLIP 文本嵌入拼接的伪文本 token，使扩散模型能够在 cross-attention 中感知相机位姿信息。
- (3) **Blender 多视角数据集自动生成管线**：搭建了从场景构建、相机轨迹采样、批量渲染到深度图/轮廓图后处理的全自动化合成数据管线，可灵活扩展至各类 3D 资产。
- (4) **多步迭代推理策略**：将大角度旋转分解为若干小角度步长的串联迭代，每步以上一步输出作为新的条件图，有效降低了单次推理的任务难度，使模型在训练阶段仅需学习小角度变换即可覆盖全范围旋转。
- (5) **完整的训练—验证—部署流程**：提供了 LoRA 训练、收敛自动验证、Gradio 交互推理界面及 ComfyUI 工作流部署的全链路实现。

1.4 章节安排

本文剩余部分组织如下：第二章综述扩散模型、可控生成、LoRA 微调、深度估计等相关工作；第三章详述整体方法设计，包括双分支架构、条件注入机制与多步推理策略；第四章介绍基于 Blender 的多视角数据集构建管线；第五章给出训练、收敛验证、推理应用及 ComfyUI 部署的实现细节；第六章分析实验结果与当前局限性；第七章总结全文并展望未来方向。

第二章 相关工作

2.1 扩散模型与文生图

扩散模型（Diffusion Models）通过逐步向数据添加高斯噪声、再学习逆向去噪过程来生成样本。Ho等人提出的 DDPM^[?]] 奠定了现代扩散模型的理论基础，Song 等人提出的 DDIM^[?]] 进一步通过确定性采样加速了推理过程。Rombach 等人提出的潜在扩散模型（Latent Diffusion Models, LDM）^[?]] 将扩散过程从像素空间迁移至预训练 VAE 的 latent 空间，大幅降低了计算开销，其开源实现 Stable Diffusion 成为当前最广泛使用的文生图基础模型之一。

2.2 扩散模型的条件控制

原始的文生图扩散模型仅以文本嵌入作为条件，对空间结构的控制能力有限。ControlNet^[?]] 提出了一种可插拔的条件控制架构：复制预训练 UNet 的编码器部分作为“可训练副本”，通过零初始化卷积层（zero-convolution）逐步将外部条件（如深度图、边缘图、姿态骨骼等）注入主 UNet，在保持原模型生成能力的同时赋予其结构约束。Canny 边缘检测算法^[?]] 作为经典的图像边缘提取方法，与 ControlNet 结合后可以有效锁定生成图像的轮廓与构图。

InstructPix2Pix^[?]] 将图像编辑任务建模为条件扩散生成问题，其 UNet 的输入卷积层（conv_in）原生支持 8 通道输入——前 4 通道对应带噪 latent，后 4 通道对应参考图像的 VAE latent。这一设计使得模型可直接在 latent 空间接收参考图的条件信号，为本文的方法设计提供了重要启发。SDEdit^[?]] 则从 SDE 视角提供了另一种图像编辑的思路：向输入图像添加适量噪声后，在反向扩散过程中引入编辑引导。

2.3 参数高效微调：LoRA

LoRA（Low-Rank Adaptation）^[?]] 是一种参数高效微调方法，其核心思想是将预训练权重的增量更新分解为两个低秩矩阵的乘积： $W' = W + \Delta W = W + BA$ ，其中 $B \in \mathbb{R}^{d \times r}$ ， $A \in \mathbb{R}^{r \times k}$ ， $r \ll \min(d, k)$ 。训练时仅更新 A 和 B ，冻结原始权重 W 。在扩散模型领域，LoRA 被广泛用于注入特定风格、物体或控制能力，只需训练极少参数

(通常不到总参数的 1%), 即可显著改变模型行为。本文在 InstructPix2Pix UNet 的注意力层上挂载 LoRA, 使其学习”参考结构图 + 旋转向量 $\rightarrow$ 目标结构图”的映射关系。

2.4 单目深度估计

Depth Anything V2^[7] 是一种基于大规模数据训练的单目深度估计模型, 能够从单张 RGB 图像中预测高质量的相对深度图。该模型采用 DINOv2 作为视觉编码器, 在多种场景下展现出优异的泛化能力。本文在数据管线中利用 Depth Anything V2 为渲染的 RGB 图像批量生成深度图, 作为 depth 分支的条件输入。

2.5 新视角合成

新视角合成 (Novel View Synthesis) 旨在从一组已知视角的图像中生成新视角下的场景外观。NeRF^[7] 通过多层感知机隐式表示场景的辐射场与密度场, 实现了照片级真实感的新视角渲染。3D Gaussian Splatting^[7] 则采用显式的三维高斯椭球体表示, 在大幅提升渲染速度的同时保持了高质量。然而, 这些方法通常需要数十至上百张标定图像作为输入, 且对每场景需独立优化。本文的方法与之互补——扩散模型可从单张参考图直接泛化到新视角, 输出结果可作为 NeRF/3DGS 的输入, 用于后续的显式三维重建。

2.6 CLIP 与多模态对齐

CLIP (Contrastive Language-Image Pre-training)^[7] 通过对比学习将图像与文本映射到共享的嵌入空间, Stable Diffusion 使用其文本编码器将 prompt 转换为条件向量。本文在此基础上, 将 RotationEncoder 产生的旋转嵌入作为额外的”伪文本 token”拼接到 CLIP 输出后, 使 UNet 的 cross-attention 层能同时关注文本语义与相机位姿信息。

第三章 整体方法设计

本章系统阐述所提出的多模态条件扩散方案。首先介绍总体架构与双分支设计，然后依次详述底模选择、条件注入机制（结构图条件与旋转向量条件）、LoRA微调策略、训练时的相邻视角配对策略，以及推理时的多步迭代策略。

3.1 总体架构

系统的总体架构如图 3.1 所示。整个流程分为训练与推理两个阶段：训练阶段以 Blender 合成数据集中的相邻视角对为样本，冻结 InstructPix2Pix 底模，仅训练 UNet 上的 LoRA 适配器与 RotationEncoder；推理阶段用户上传参考 RGB 图，系统自动提取深度图与轮廓图作为初始条件图，用户指定目标旋转角度后，模型通过多步迭代生成目标视角的结构图。




图 3.1: 系统总体架构图。上半部分为训练流程，下半部分为推理流程。推理阶段大角度旋转通过多步迭代实现，每步以上一步输出为新条件图。

3.2 底模选择：InstructPix2Pix

在底模选择上，本文没有直接使用标准的 Stable Diffusion v1.5（其 UNet conv_in 为 4 通道，仅接收带噪 latent），而是选用了 **InstructPix2Pix**^[?]]。其核心优势在于：UNet 的输入卷积层（conv_in）原生设计为 8 通道输入，前 4 通道对应带噪目标 latent $\mathbf{z}_t$ ，后 4 通道对应参考图像（条件图）的 VAE latent $\mathbf{z}_c$ ：

$$\mathbf{z}_{\text{input}} = \text{concat}(\mathbf{z}_t, \mathbf{z}_c) \in \mathbb{R}^{B \times 8 \times H/8 \times W/8} \quad (3.1)$$

这一设计使得模型不再需要从零学习一套条件注入权重——InstructPix2Pix 已在大规模图像编辑数据集上预训练收敛，后 4 通道已经学会了“如何根据参考 latent 调节生成过程”。本文只需在此基础上挂载 LoRA，微调模型使其适应“参考结构图 + 旋转向量 $\rightarrow$ 目标结构图”的新任务。训练过程中，底模的所有原始参数（UNet、VAE、CLIP 文本编码器）均保持冻结。

3.3 双分支设计

系统包含两个独立的分支：**depth** 分支和 **canny** 分支。两个分支共享相同的模型架构（InstructPix2Pix + LoRA + RotationEncoder），但各自独立训练、权重互不共享。二者的区别在于：


- **depth 分支**：使用 Depth Anything V2^[?]] 从参考 RGB 图提取的深度图作为条件图。深度图是 16bit 单通道图像，归一化后复制为 3 通道供 VAE 编码，携带空间远近与透视结构信息。
- **canny 分支**：使用 Canny 边缘检测算法^[?]] 从参考 RGB 图提取的轮廓图作为条件图。轮廓图是 8bit 单通道二值图像，同样复制为 3 通道，携带物体轮廓与边缘结构信息。

双分支独立训练/推理的设计，确保两类几何线索（深度与轮廓）各自得到充分学习，且两个分支的结果可在下游任务中互补使用。


3.4 条件注入机制

本系统的条件注入包含三条并行的路径，如图 3.2 所示。

路径 1: 结构图条件



路径 2: 旋转向量条件



路径 3: 文本条件



图 3.2: 条件注入机制示意图。三条路径分别将结构图、旋转向量和物品文本注入扩散模型。

3.4.1 结构图条件注入

参考结构图（深度图或轮廓图）首先经 VAE 编码器映射到 latent 空间，得到条件 latent $\mathbf{z}_c$:

$$\mathbf{z}_c = \mathcal{E}_{\text{VAE}}(I_{\text{cond}}) \cdot s_{\text{VAE}} \quad (3.2)$$

其中 s_{VAE} 为 VAE 的缩放因子 (scaling_factor, 通常为 0.18215)。在 UNet 的前向传播中, $\mathbf{z}_c$ 与当前时间步的带噪 latent $\mathbf{z}_t$ 在通道维度拼接, 形成 8 通道输入送入 UNet。

3.4.2 旋转向量条件注入

三维旋转向量 $\mathbf{r} = [\Delta\theta_{\text{az}}, \Delta\theta_{\text{el}}, \Delta\theta_{\text{roll}}]^\top$ (单位: 度) 需转换为扩散模型可理解的形式。本文采用“sin/cos 编码 + MLP 映射”的方案:

步骤一: 周期编码。角度量本质上是周期性的 (0° 与 360° 代表同一朝向), 直接将原始角度值输入 MLP 会在边界处引入跳变伪影。因此, 首先将角度转为弧度后对每个分量分别取正弦和余弦, 将 3 维角度向量扩展为 6 维连续特征:

$$\mathbf{f}_{\text{sincos}} = [\sin(\mathbf{r}'), \cos(\mathbf{r}')] \in \mathbb{R}^6, \quad \mathbf{r}' = \mathbf{r} \cdot \frac{\pi}{180^\circ} \quad (3.3)$$

步骤二: MLP 升维。将 6 维特征送入一个两层 MLP (含 SiLU 激活), 映射到与 CLIP 文本嵌入相同的维度 (768 维), 再 reshape 为长度 1 的“伪文本 token”:

$$\mathbf{e}_{\text{rot}} = \text{MLP}(\mathbf{f}_{\text{sincos}}) \in \mathbb{R}^{1 \times 768} \quad (3.4)$$

步骤三: 与文本嵌入拼接。将 $\mathbf{e}_{\text{rot}}$ 与 CLIP 文本编码器输出的 77 个文本 token 在序列维度拼接, 形成 $(B, 78, 768)$ 的条件序列, 作为 UNet cross-attention 的 key/value:

$$\mathbf{E}_{\text{cond}} = \text{concat}(\text{CLIP}(T), \mathbf{e}_{\text{rot}}) \in \mathbb{R}^{B \times 78 \times 768} \quad (3.5)$$

其中 T 为从数据集 `object_source` 字段解析出的物品名称文本 prompt（如"`coffee table`"），而非固定空字符串，使得文本分支携带物体语义信息。

3.4.3 分类器无关引导（CFG）

推理时采用标准的分类器无关引导（Classifier-Free Guidance）。无条件分支使用空文本 $T_\emptyset$ 编码，但保留相同的 $\mathbf{e}_{\text{rot}}$ （即无条件分支仅去掉文本语义、保留旋转条件）。设 ϵ_θ 为 UNet 预测的噪声，CFG 的最终噪声估计为：

$$\hat{\epsilon}_\theta(\mathbf{z}_t, \mathbf{z}_c, \mathbf{E}_{\text{cond}}) = \epsilon_\theta(\mathbf{z}_t, \mathbf{z}_c, \mathbf{E}_\emptyset) + w \cdot (\epsilon_\theta(\mathbf{z}_t, \mathbf{z}_c, \mathbf{E}_{\text{cond}}) - \epsilon_\theta(\mathbf{z}_t, \mathbf{z}_c, \mathbf{E}_\emptyset)) \quad (3.6)$$

其中 w 为文本 guidance scale（默认 7.5）， $\mathbf{E}_\emptyset$ 为将 CLIP 文本部分替换为空字符串编码、保留 $\mathbf{e}_{\text{rot}}$ 后的条件嵌入。

3.5 LoRA 微调策略

LoRA 仅挂载在 UNet 的注意力层上，目标模块为 `to_q`、`to_k`、`to_v`、`to_out.0`。LoRA 秩 $r = 4$ ，低秩分解矩阵以高斯分布初始化， $\alpha = r$ 。训练时 LoRA 参数与 RotationEncoder 参数共同优化，VAE、CLIP 文本编码器、UNet 原始权重全部冻结。

训练目标为标准噪声预测损失（简化的 DDPM 目标）：

$$\mathcal{L} = \mathbb{E}_{\mathbf{z}_t, \mathbf{z}_c, \mathbf{E}_{\text{cond}}, \epsilon, t} [\|\epsilon - \epsilon_\theta(\mathbf{z}_t, \mathbf{z}_c, \mathbf{E}_{\text{cond}}, t)\|_2^2] \quad (3.7)$$

其中 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 为真实噪声， $t \sim \text{Uniform}(1, T)$ 为随机采样的时间步。

3.6 训练策略：相邻视角配对

训练时并非任意两个视角的组合都作为样本，而是限定为同一场景内、同一 `elevation` 行中 `azimuth` 相邻的视角对。这一设计的动机在于：

- (1) **降低单步任务难度**：相邻视角间的旋转角度通常较小（ $\approx 10^\circ \sim 30^\circ$ ），模型更容易学习小角度下的结构变化规律，loss 收敛更稳定。
- (2) **大角度由推理阶段解决**：任意大角度的视角变换在推理时通过多步迭代实现（见第 3.7 节），训练阶段无需覆盖全范围旋转。
- (3) **双向训练消除方向偏置**：每个相邻对 (a, b) 生成两个训练样本： $a \rightarrow b$ 和 $b \rightarrow a$ ，使模型同时学习正向与反向旋转。

具体地，对于每个场景的所有非参考视角（参考视角固定为正对物体的方位角 0° 、俯仰角 0° ，不参与配对），先按 elevation 分组，组内按 azimuth 升序排列，取所有 $(i, i+1)$ 相邻对；若该行覆盖了接近完整的 360° ，则额外补充首尾循环相邻组合。

3.7 推理策略：多步迭代大角度变换

由于训练阶段模型仅学习小角度旋转变换，对于用户指定的大角度旋转（如 $\Delta\text{azimuth} = 150^\circ$ ），直接单次推理会导致生成质量严重下降。本文采用**多步迭代推理**策略，将大角度旋转分解为若干小步长，串联执行。

设用户指定的总旋转为 $\mathbf{R}_{\text{total}}$ ，单步步长上限为 δ_{max} （默认 10° ）。分解步数 N 为：

$$N = \left\lceil \frac{\max(|\Delta\text{az}|, |\Delta\text{el}|)}{\delta_{\text{max}}} \right\rceil \quad (3.8)$$

每步的旋转向量为 $\mathbf{r}^{(k)} = \mathbf{R}_{\text{total}}/N$ 。从初始条件图 $I_{\text{cond}}^{(0)}$ （即参考图的深度图/轮廓图）出发，第 k 步（ $k = 1, 2, \dots, N$ ）执行：

$$I_{\text{cond}}^{(k)} = \text{Infer}(I_{\text{cond}}^{(k-1)}, \mathbf{r}^{(k)}) \quad (3.9)$$

其中 $\text{Infer}(\cdot)$ 为单步扩散推理过程。最终输出 $I_{\text{cond}}^{(N)}$ 即为目标视角下的结构图。这一迭代策略使得模型只需具备小角度变换能力，即可通过串联覆盖任意旋转幅度。

第四章 基于 Blender 的多视角数据集构建管线

训练第三章所述的条件扩散模型需要大量带有精确相机位姿标注的多视角图像数据。由于真实场景下获取这类标注的成本极高，本文设计并实现了一套基于 Blender 的自动化合成数据管线，覆盖场景搭建、相机轨迹采样、批量渲染、条件图后处理与数据集拆分全流程。管线架构如图 4.1 所示。




图 4.1: 数据集构建管线总览

4.1 场景搭建

每个场景由 `scene_builder.py` 负责搭建，遵循以下统一规范以确保跨场景光照与背景条件一致：

- **场景清理**：清空 Blender 默认场景中的所有物体（Cube、Light、Camera）及孤立数据块。
- **地面平面**： 20×20 Blender 单位的方形平面，材质为中性灰（RGB = (0.5, 0.5, 0.5)）、粗糙度 1.0（完全漫反射，不反光），避免高光干扰后续轮廓识别。
- **三点光照**：采用 key / fill / back 三盏 Area Light，固定色温 6500K，光强分别为 1000W / 400W / 600W。三盏灯分别位于物体前方右侧 45° 、前方左侧 45° 和正后方，均朝向物体几何中心，保证光照条件在跨场景间严格可复现。
- **世界背景**：纯色中性灰背景（RGB = (0.4, 0.4, 0.4)），简化后续抠图与对齐判断。
- **物体归一化**：将加载的 3D 模型统一缩放到最大包围盒边长为 2.0 Blender 单位，并将几何中心平移至世界原点。这是确保相机绕物体旋转时所有视角下物体均完整可见的必要前提。

当外部 3D 模型资产不可用时,管线自动降级为内置几何体(Cube、Sphere、Cylinder、Cone、Torus、Monkey) 轮换使用,以保证管线在任何情况下均可跑通验证。正式交付数据集建议替换为 CC0 或自有 .obj/.fbx/.glb 模型资产。

4.2 相机轨迹生成

相机位姿由 `camera_trajectory.py` 按分层网格采样策略自动生成,以保证 azimuth 和 elevation 方向上的均匀分布。核心步骤:

- (1) **固定参考视角:** 强制包含一个方位角 0° 、俯仰角 0° 的正对物体视角 (`view_id = "ref"`), 作为训练三元组中的“参考视角”。
- (2) **分层网格采样:** 将剩余视角数分解为 $n_{\text{elevation}}$ 行 $\times$ n_{azimuth} 列的近似正方形网格。每行固定一个 elevation 值 (在 $[-30^\circ, 60^\circ]$ 范围内均匀分布), 行内 azimuth 在 $[0^\circ, 360^\circ)$ 上均匀分布, 并加入小幅随机抖动 ($\leq$ 半个网格间隔的 30%) 以避免机械感。
- (3) **球坐标转笛卡尔坐标:** 相机位置计算为 $(x, y, z) = (d \cos(\text{el}) \cos(\text{az}), d \cos(\text{el}) \sin(\text{az}), d \sin(\text{el}))$, 其中 $d = 5.0$ Blender 单位为相机到物体中心的距离。
- (4) **Look-At 定向:** 每台相机通过 `to_track_quat` ($-Z$ 轴朝目标, Y 轴朝上) 计算欧拉角, 而非依赖 Track-To 约束, 避免约束求值时机导致的朝向错误。

每个场景默认生成 30 个视角 (含 1 个参考视角 + 29 个网格采样视角), 可通过 `--views_per_scene` 参数调整。所有位姿数据 (包括 azimuth、elevation、欧拉角、世界坐标等) 记录在每场景的 `poses.json` 中。

4.3 批量渲染

批量渲染由 `render_pipeline.py` 作为命令行入口脚本在 Blender `--background` 无界面模式下运行。关键渲染配置如下:

- **渲染引擎:** 默认 `EEVEE_NEXT` (GPU 光栅化, 速度远快于 Cycles), 可选 `CYCLES` 以获取更高画质的路径追踪结果。Cycles 模式下优先启用 `OPTIX` (NVIDIA RTX 系列) 或 `CUDA GPU` 加速。
- **输出分辨率:** 统一 512×512 像素, PNG 格式, RGBA 色彩模式。
- **色调映射:** 显式切换为 `Standard` (线性映射), 避免 Blender 5.0 默认的 `AgX` 色调映射导致的对比度压缩与整体发灰。

- **性能优化**: 采样数 32 (降低单帧渲染时间)、启用降噪 (补偿低采样的画质损失)、分块尺寸 256。
- **异常处理**: 单帧渲染失败不导致整个 pipeline 崩溃, 记录错误信息并跳过继续渲染下一视角。

4.4 条件图后处理

由于 Blender 5.0 对 Compositor 节点 API 进行了大幅重构, 在 `--background` 模式下程序化导出深度图/轮廓图的技术路径已被判定不可行。因此, 渲染阶段仅产出 RGB 图像, 深度图与轮廓图由独立的 `export_conditions.py` 在渲染完成后基于已落盘的 RGB 图进行后处理生成:

- **深度图**: 使用 Depth Anything V2 (Large 模型) [?] 对每张 RGB 图进行批量推理, 输出 16bit 单通道 PNG。深度值归一化至 $[0, 65535]$, 与源 RGB 图分辨率严格一致、像素坐标对齐。
- **轮廓图**: 直接对同一张 RGB 原图使用 OpenCV 的 Canny 边缘检测 (低阈值 100, 高阈值 200), 输出 8bit 单通道 PNG。对 RGB 原图而非深度图做边缘检测, 确保轮廓反映的是物体在图像上的真实边缘。

每张 RGB 图的深度图路径 (`depth_path`) 与轮廓图路径 (`edge_path`) 在渲染阶段已预写入 `poses.json` 的对应条目中。

4.5 数据集拆分

数据集拆分由 `split_dataset.py` 完成。为避免数据泄漏, 默认采用按场景整体划分的策略: 同一场景的所有视角 (含参考视角) 要么全在训练集, 要么全在验证集, 不会同时出现在两侧。拆分比例为 9:1 (train:val), 随机种子固定为 42 以保证可复现。拆分结果输出为 `train_manifest.json` 与 `val_manifest.json`, 每个条目内联展开完整的位姿标注字段 (`image_path`、`azimuth_deg`、`elevation_deg`、`euler_xyz_deg`、`camera_position_xyz`、`depth_path`、`edge_path` 等), 训练脚本无需再关联查询 `poses.json`。

4.6 数据集规模与标注格式

以 `render_pipeline.py` 默认参数为例: $200 \text{ 个场景} \times 30 \text{ 视角/场景} = 6000 \text{ 帧 RGB 图像}$, 远超过 5000 样本的最低要求。每个场景的 `poses.json` 包含该场景所有视角的位姿标注, 格式如下:


```
{  
  "view_id": 0,  
  "azimuth_deg": 15.3,  
  "elevation_deg": -20.0,  
  "distance": 5.0,  
  "euler_xyz_deg": [20.0, 0.0, 15.3],  
  "camera_position_xyz": [1.2, 0.3, -1.7],  
  "image_path": "scene_0000/view_0.png",  
  "depth_path": "scene_0000/depth_0.png",  
  "edge_path": "scene_0000/edge_0.png",  
  "is_reference": false  
}
```

第五章 实现细节

本章在前两章方法设计与数据管线的基础上，给出训练流程、显存优化、收敛验证、推理应用与 ComfyUI 部署的具体实现细节。

5.1 训练流程

5.1.1 模型加载与 LoRA 挂载

训练脚本 `train_lora.py` 首先从 HuggingFace Hub（或本地缓存）加载 InstructPix2Pix 的四个子模块：`CLIPTokenizer`、`CLIPTextModel`、`AutoencoderKL`、`UNet2DConditionModel` 和 `DDPMScheduler`。加载后立即验证 UNet `conv_in` 的输入通道数为 8（断言保护），确保底模正确。

随后冻结所有底模参数（VAE、Text Encoder、UNet 原始权重），在 UNet 的注意力层上挂载 LoRA 适配器。LoRA 配置为：目标模块 `[to_q, to_k, to_v, to_out.0]`，秩 $r = 4$ ， $\alpha = r$ ，以高斯分布初始化。RotationEncoder 为随机初始化（或从断点恢复）的两层 MLP（ $6 \rightarrow 256 \rightarrow 768$ ，SiLU 激活）。

5.1.2 数据集与 DataLoader

训练数据集 `AdjacentPairDataset`（`dataset.py`）从 `train_manifest.json` 中加载所有场景的视角标注，按 `elevation` 分组后构建相邻视角对。每个样本返回：参考条件图张量（ $3 \times 512 \times 512$ ，归一化至 $[-1, 1]$ ）、目标条件图张量（同尺寸）、相对旋转向量（`[\Delta az, \Delta el, \Delta roll]`，单位度）、以及物品名称 `prompt` 字符串。

`DataLoader` 采用 `batch_size = 1`（受限于 16G 显存），`shuffle = True`。Windows 下为避免多进程 `spawn` 带来的重型依赖重复导入开销，默认 `num_workers = 0`（主进程内加载）。

5.1.3 训练循环

训练使用 HuggingFace Accelerate 库管理混合精度与梯度累积。每个训练步：

- (1) 参考条件图与目标条件图分别经 VAE 编码为 latent $\mathbf{z}_c^{\text{ref}}$ 与 $\mathbf{z}_c^{\text{tgt}}$ 。

- (2) 向 $\mathbf{z}_c^{\text{tgt}}$ 添加随机噪声得到 $\mathbf{z}_t$ 。
- (3) 物品名称 prompt 经 CLIP tokenizer + text_encoder 编码为 (1, 77, 768) 文本嵌入。
- (4) 旋转向量经 RotationEncoder 编码为 (1, 1, 768) 旋转嵌入，与文本嵌入拼接为 (1, 78, 768)。
- (5) $\mathbf{z}_t$ 与 $\mathbf{z}_c^{\text{ref}}$ 在通道维拼接为 8 通道输入，送入 UNet 预测噪声 $\hat{\epsilon}$ 。
- (6) 计算 $\mathcal{L}_{\text{MSE}} = \|\epsilon - \hat{\epsilon}\|_2^2$ ，执行反向传播。
- (7) 每 gradient_accumulation_steps 步后更新一次优化器参数。

优化器为 AdamW，初始学习率 1×10^{-4} 。每个 epoch 结束后将完整训练状态（LoRA adapter、RotationEncoder、优化器、epoch、global_step）保存为 checkpoint，并支持从中断处恢复续训。

5.2 显存优化

面向 RTX 4060 16G 显存的硬件约束，训练流程集成了三项显存优化措施：

- **混合精度训练**：默认 fp16，将模型前向/反向传播中的浮点运算降至半精度，显著降低显存占用与计算时间。
- **梯度检查点（Gradient Checkpointing）**：在 UNet 前向传播中不保存中间激活值，反向传播时重新计算，以时间换空间。
- **梯度累积**：batch_size = 1 + gradient_accumulation_steps = 4，等效 batch size 为 4。每次仅前向单个样本，累积 4 步梯度后再统一更新参数，避免大 batch 带来的显存峰值。

上述配置下，训练全流程（模型权重 + 优化器状态 + LoRA 梯度 + 激活值）可稳定运行于 16G 显存，无需 CPU offload。

5.3 收敛验证

verify_lora_convergence.py 提供了一套不依赖 GPU 的自动化收敛判定脚本。训练过程中每 10 步记录一次 loss 到 loss_history.json。收敛判定的三个维度：

- (1) **趋势下降**：将 loss 序列均分为前、中、后三段，要求后段均值较前段均值下降幅度 $\geq 15\%$ (min_drop_ratio)。

- (2) **稳定性**: 取最后 20% 的 loss 窗口, 要求其标准差/均值比 ≤ 0.5 (`max_tail_std_ratio`), 判断是否收敛至稳定区间。
- (3) **数值有效性**: 检测 NaN/Inf, 作为梯度爆炸的预警信号。

三个条件同时满足时判定为”收敛通过”, 脚本输出每个 LoRA 分支的详细信息与整体摘要。

5.4 推理应用

5.4.1 Gradio 交互界面

`inference_app.py` 使用 Gradio 框架提供了一个完整的 Web 推理调试界面(图 5.1)。界面功能包括:

- **自动条件图提取**: 用户上传参考 RGB 图后, 系统即时调用 Depth Anything V2 与 Canny 算法分别提取深度图与轮廓图预览, 无需等待点击生成按钮。
- **双分支独立推理**: depth分支与 canny 分支各自加载独立的 LoRA checkpoint (或留空退化为 InstructPix2Pix 原生图生图模式), 并行生成结果。
- **多步迭代可视化**: 生成过程中保存每步中间结果, 以 Gallery 形式展示完整的迭代轨迹。
- **参数可调**: 支持调节旋转角度 (azimuth $[-180^\circ, 180^\circ]$, elevation $[-90^\circ, 90^\circ]$)、单步步长、采样步数、guidance scale、随机种子等参数。

图 5.1: Gradio 推理调试界面

5.4.2 双模式推理

`InferencePipeline` 类封装了两种互斥的推理模式, 由 LoRA 目录是否为空自动切换:

- **结构图视角变换模式** (LoRA 目录非空): 加载训练好的 LoRA + RotationEncoder 权重, 走完整的”条件图 latent 拼接 + 旋转向量 cross-attention 注入 + 多步迭代”管线。
- **原生图生图模式** (LoRA 目录为空, 默认): 直接调用 diffusers 官方的 `StableDiffusionInstructPix2Pix` 以 InstructPix2Pix 底模原生的图像编辑能力对 RGB 参考图进行编辑。此模式不涉及 RotationEncoder 或条件 latent 拼接, 但保证了”无 LoRA 时也能正常读图出图”, 便于在 LoRA 训练完成前验证全链路。

5.5 ComfyUI workflow部署

除了 Python 脚本推理外，项目还提供了 `camera_control.json` ComfyUI 工作流，将核心流程封装为可视化节点图。工作流包含以下节点链：

Load Image → Depth Anything V2 → ControlNet (Depth) → KSampler → VAE Decode → Save Image

同时接入 Canny 边缘检测 + ControlNet (Canny) 并行路径，并加载 LoRA 权重。用户仅需替换输入图像与 prompt 即可运行，无需编写代码。运行硬件为 NVIDIA RTX 4060 16G，ComfyUI 工作流经过验证可稳定运行。

5.6 运行环境与依赖

训练与推理的 Python 依赖包括：PyTorch、Diffusers、Transformers、Accelerate、PEFT、Pillow、NumPy、OpenCV-Python 和 Gradio（完整列表见 `training/requirements.txt`）。数据集生成管线需要 Blender（可在命令行以 `--background` 模式调用）。所有实验在 Windows 系统、NVIDIA RTX 4060 16G GPU 上完成。

第六章 实验结果与局限分析

本章从实验设置、定性结果、定量评估和局限性四个维度对系统进行分析讨论。

6.1 实验设置

6.1.1 数据集

实验使用 Blender 合成数据集，包含 200 个场景，每场景 30 个视角（含 1 个参考视角），总计 6000 帧 512×512 的 RGB 图像及对应的深度图和轮廓图。场景中的物体包括内置几何体（Cube、Sphere、Cylinder、Cone、Torus、Monkey）与外部 3D 模型（Camera_01、CoffeeTable_01、Lantern_01 等 CC0 资产）。数据集按场景以 9:1 比例拆分为训练集（180 个场景，约 5400 帧）和验证集（20 个场景，约 600 帧）。

6.1.2 训练配置

depth 分支与 canny 分支各自独立训练，均采用以下配置：

- 底模：timbrooks/instruct-pix2pix (InstructPix2Pix)
- LoRA 秩： $r = 4$ ，目标模块：to_q, to_k, to_v, to_out.0
- 学习率： 1×10^{-4} ，优化器：AdamW
- 等效 batch size：4 (batch_size=1 + gradient_accumulation_steps=4)
- 训练 epoch：10
- 混合精度：fp16
- 梯度检查点：开启

6.1.3 硬件环境

- GPU：NVIDIA GeForce RTX 4060 (16GB VRAM)

- CPU: Intel Core i7-13700
- 内存: 32GB DDR5
- 操作系统: Windows 11

6.2 定性结果

图 6.1 与图 6.2 分别展示了 depth 分支与 canny 分支在不同旋转角度下的生成结果。每个示例从左至右依次为：参考 RGB 图、自动提取的初始条件图（深度图/轮廓图）、以及模型在不同目标旋转角度下生成的结构图。

图 6.1: depth 分支：不同方位角旋转下的深度图生成结果。第一列为参考 RGB 图，第二列为参考深度图，后续各列为不同 $\Delta\text{azimuth}$ 下的生成深度图。

图 6.2: canny 分支：不同方位角旋转下的轮廓图生成结果。布局同上。

6.2.1 小角度变换

当目标旋转角度较小 ($\Delta\text{azimuth} \leq 30^\circ$) 时，depth 分支和 canny 分支均能稳定生成与目标视角一致的结构图：深度图正确反映了旋转后的空间远近关系（近大远小），轮廓图保持了物体的主要边缘结构。

6.2.2 大角度多步迭代

图 6.3 展示了多步迭代过程中间结果的可视化。以 $\Delta\text{azimuth} = 150^\circ$ 、单步步长 10° 为例，模型经过 15 步串联迭代从初始深度图逐步变换至目标视角。每步之间的变化是渐进且连贯的，验证了多步迭代策略的有效性。但由于每步的微小误差会随步数累积，步数较多时可能在物体细节（如纹理边界、细小结构）上出现逐步模糊或漂移。

图 6.3: 多步迭代推理中间结果 ($\Delta\text{azimuth} = 150^\circ$ ，步长 10° ，共 15 步)。

6.2.3 双分支对比

depth 分支生成的深度图在表达空间远近关系上更为准确（因为深度图本身就是空间距离的编码），但在物体轮廓细节上不如 canny 分支锐利。canny 分支生成的轮廓图边缘清晰、结构明确，但缺乏空间深度的层次感。二者在应用中互为补充：深度图适合需要空间感知的下游任务（如 3D 重建），轮廓图适合需要精确边缘约束的任务（如 ControlNet 结构控制）。

6.3 定量评估

6.3.1 Loss 收敛曲线

图 6.4 展示了 depth 分支和 canny 分支在训练过程中的 loss 下降曲线。两个分支均呈现出明显的下降趋势——前段 loss 快速下降，中后段趋于平缓稳定。收敛验证脚本的输出确认两个分支均通过了趋势下降（下降幅度 $> 15\%$ ）与稳定性（末尾窗口波动比 ≤ 0.5 ）两项判定。

图 6.4: depth 分支与 canny 分支的训练 loss 收敛曲线

6.3.2 结构相似性

为定量评估生成结构图与真实目标结构图之间的一致性，可在验证集上计算以下指标（作为拟定实验方案供后续实施）：

- **SSIM（结构相似性指数）**：衡量生成图与真值图在亮度、对比度与结构上的相似程度。对于深度图，SSIM 可反映空间关系的保留程度；对于轮廓图，SSIM 可反映边缘结构的准确性。
- **MSE / MAE**：像素级误差度量，评估深度值或边缘强度的数值偏差。
- **LPIPS（Learned Perceptual Image Patch Similarity）**：基于深度特征的感知相似度，更贴合人眼感知。

由于 depth 分支和 canny 分支目前仅生成结构图（非 RGB 图像），传统的 FID（Fréchet Inception Distance）等面向 RGB 图像质量的指标不直接适用。建议在后续将结构图通过 ControlNet 引导生成 RGB 图后，再计算 FID 等图像质量指标。

6.4 局限性与讨论

尽管系统在结构图视角变换任务上展现出良好的能力，但仍存在以下局限，需要在未来工作中加以解决：

- (1) **非严格 6DoF 相机控制**：当前系统的旋转条件仅包含 azimuth、elevation 和 roll 三个欧拉角，未对相机位置（平移）、焦距、视场角等进行建模。相机始终固定在以物体为中心、半径 5.0 的球面上，尚未实现完整的六自由度控制。
- (2) **结构图而非 RGB 图生成**：模型当前仅生成目标视角的深度图/轮廓图（结构图），而非完整的 RGB 图像。虽然结构图可作为 ControlNet 的输入进一步生成 RGB 图，但这一额外的步骤引入了信息损失与生成不确定性。

- (3) **合成数据的 Domain Gap:** 训练数据完全来自 Blender 渲染的合成场景（简单几何体 + 中性灰背景 + 固定光照），与真实世界图像存在显著的分布差异。模型在真实照片上的泛化能力有待验证。
- (4) **多步迭代的误差累积:** 大角度旋转需要多步迭代，每步的微小生成误差会在串联过程中逐步累积，导致步数较多时出现细节模糊、结构漂移等问题。如何引入闭环校正或跨步一致性约束是值得探索的方向。
- (5) **物体类别覆盖有限:** 当前数据集中的物体类别较少（内置几何体 + 少量 CC0 模型），模型对复杂形状、纹理丰富或具有精细结构的物体可能泛化不足。
- (6) **roll 角标签缺失:** Blender 渲染数据集中相机仅绕 azimuth 和 elevation 旋转，未提供可靠的 roll 角变化标签。因此推理界面中 roll 角滑块被禁用（恒为 0），模型未学习 roll 方向的变换。
- (7) **多视角一致性未显式约束:** 当前 depth 和 canny 分支独立处理每个目标视角，未在多个目标视角之间施加一致性约束（如跨视角 attention 或几何一致性 loss）。连续多个视角的生成结果之间可能出现结构跳变或不一致。

第七章 总结与展望

7.1 工作总结

本文围绕”基于扩散模型的多视角相机镜头控制图像生成”这一核心任务，提出了一套以 InstructPix2Pix 为底模、以 LoRA 为轻量微调手段的多模态条件扩散方案。主要工作可以概括为以下四个方面：

第一，方法层面，提出了结构图视角变换的新范式：将抽象的相机控制问题转化为扩散模型可理解的结构图变换问题，以深度图/轮廓图作为中间条件表示，复用 InstructPix2Pix 原生的 8 通道 UNet 实现条件 latent 注入，无需从零训练条件权重。设计了 RotationEncoder (sin/cos 编码 + MLP)，将三维旋转向量转换为可与 CLIP 文本嵌入拼接的伪文本 token，使相机位姿信息进入 UNet cross-attention 路径。

第二，数据层面，搭建了基于 Blender 的全自动化多视角合成数据管线，覆盖场景搭建、分层网格相机轨迹采样、批量渲染、Depth Anything V2 深度图/Canny 轮廓图后处理、以及按场景拆分的 train/val 划分全流程。管线支持内置几何体降级与外部 3D 模型扩展，可通过命令行参数灵活调节场景数、视角数、分辨率、渲染引擎等。

第三，训练层面，设计了相邻视角配对策略，将训练任务从”任意角度旋转”收窄为”小角度相邻旋转变换”，降低了单步学习难度，提升了 loss 收敛稳定性。结合双向训练消除方向偏置，并通过多步迭代推理将大角度旋转分解为串联的小步长序列，使模型仅需小角度能力即可覆盖任意旋转幅度。

第四，工程层面，提供了完整的训练—验证—推理—部署链路：LoRA 训练脚本支持断点续训、显存优化、混合精度与梯度累积；自动化收敛验证脚本无需 GPU 即可检测 loss 下降趋势与稳定性；Gradio 推理界面支持双分支独立生成、多步迭代可视化、以及 LoRA 缺失时自动退化为底模原生图生图；ComfyUI 工作流提供可视化节点部署方案。

7.2 未来工作展望

基于本文的工作基础与第 6.4 节讨论的局限性，未来可在以下方向继续深入：

- (1) **显式 6DoF 相机位姿编码**：将当前仅包含旋转向量的条件扩展为完整的 6DoF 位姿表示（位置 + 旋转），例如采用 Plücker 射线或相机外参矩阵作为条件，使模型

具备真正的三维相机控制能力。

- (2) **端到端 RGB 图像生成:** 将当前”结构图变换 + ControlNet RGB 生成”的两阶段管线整合为端到端训练, 直接从参考 RGB 图与旋转向量生成目标视角的 RGB 图像。这需要在更大规模的数据集上训练, 并可能需要引入感知损失 (如 LPIPS) 或对抗损失以提升生成质量。
- (3) **多视角一致性约束:** 引入跨视角 attention 机制或几何一致性损失 (如在 3DGS/NeRF 隐式表示空间中施加光度一致性约束), 使多个目标视角的生成结果之间保持结构、身份、材质与光照的一致性。
- (4) **更大规模与更多样化的数据集:** 使用更多样的 3D 模型资产 (如 Objaverse、ShapeNet), 添加更丰富的背景、材质与光照变化, 缩小合成数据与真实图像的 domain gap。同时可考虑在真实多视角数据集 (如 CO3D、MVMNet) 上进行微调。
- (5) **roll 角显式训练:** 在 Blender 渲染阶段显式添加相机 roll 角变化, 或在推理时通过对生成结果做后处理旋转变换来获得 roll 角标签, 使模型具备完整的 3 自由度旋转控制。
- (6) **连续镜头轨迹生成:** 利用多步迭代策略的自然扩展, 实现平滑的连续镜头轨迹 (camera path) 生成, 应用于动画分镜、虚拟场景漫游等场景。
- (7) **真实场景微调与评估:** 在真实拍摄的多视角图像上对模型进行微调, 并以人工评估或用户调研的方式验证模型在实际应用中的镜头控制准确性与生成质量。

综上所述, 本文构建的原型系统验证了”通过中间结构条件让扩散模型服从镜头控制”这一核心思路的可行性, 为后续的多视角一致生成、连续镜头生成与显式三维感知的扩散模型研究提供了可复现的基础与参照。